

Gegeben sind die Buchstaben-N-Gramm-Häufigkeiten  $f(a,a)=1$ ,  $f(a,b)=2$ ,  $f(b,a)=0$  und  $f(b,b)=1$ .

Berechnen Sie den Discount für die Glättung der Bigramm-Wahrscheinlichkeiten.

(1 Punkt)

Berechnen Sie dann die Unigramm-Häufigkeiten  $f(a)$  und  $f(b)$  einmal nach dem Standard-Backoff-Verfahren und einmal nach dem Kneser-Ney-Verfahren.

(1 Punkt)

Berechnen Sie aus den Kneser-Ney-Häufigkeiten die ungeglätteten Unigramm-Wahrscheinlichkeiten  $p(a)$  und  $p(b)$ .

(1 Punkt)

### Discount

$$N1 = 2$$

$$N2 = 1$$

$$\text{Discount\_bigram} = N1 / N1 + (2 * N2) = 2 / 2 + (2 * 1) = 2 / 4 = 0.5$$

### Unigram-Häufigkeiten

#### Standard-Backoff-Verfahren

$$f(a) = f(a,a) + f(b,a) = 1 + 0 = 1$$

$$f(b) = f(a,b) + f(b,b) = 2 + 1 = 3$$

$$p(a) = f(a) / f(a) + f(b) = 1 / 1 + 3$$

$$p(b) = f(b) / f(a) + f(b) = 3 / 1 + 3$$

#### Kneser-Ney-Verfahren

$$f^*(a) = 1(a,a) + 1(b,a) = 1 + 0 = 1$$

$$f^*(b) = 1(a,b) + 1(b,b) = 1 + 1 = 2$$

$$p(a) = f^*(a) / f^*(a) + f^*(b) = 1 / 1 + 2 = 1/3$$

$$p(b) = f^*(b) / f^*(a) + f^*(b) = 2 / 1 + 2 = 2/3$$

## Kneser-Ney Backoff-Verteilung

Bei der bisherigen Berechnung der n-1-Gramm-Häufigkeiten zur Schätzung der Backoff-Verteilung summieren wir die Häufigkeiten über alle möglichen Vorgängerwörter  $w'$ :

$$f(C, w) = \sum_{w'} f(w', C, w)$$

$C$  ist eine (eventuell leere) Folge von Wörtern.

Bei Kneser-Ney zählen wir, wieviele **unterschiedliche** Wörter vor dem Wort-n-Gramm aufgetreten sind:

$$f^*(C, w) = \sum_{w'} \mathbf{1}_{f(w', C, w) > 0}$$

$\mathbf{1}_{test}$  ist 1, falls  $test$  wahr ist und sonst 0.

Die Kneser-Ney-Methode zählt n-Gramm-Types (statt -Tokens).

Aus den so ermittelten Häufigkeiten, werden dann die Parameter der Backoff-Wahrscheinlichkeits-Verteilungen geschätzt.

$$p_{backoff}(w|C) = \frac{f^*(C, w)}{\sum_{w'} f^*(C, w')}$$